

专家1初审意见修改说明：

(1) 有一定的修改，但是在撰写规范性方面还需要进一步优化，例如，“本文”使用过多，很多地方并不需要；应该引用的文字和图片没有标注引用；论文的标题虽然专家之前的修改意见是建议在内容上体现预测，但是标题不能简单的加一个词；等等。

修改说明：

- 1.重新优化文章用词规范，删除了一些不必要的用词，如“本文”、“本章”等；
- 2.为一些该引用的文字标注引用，如1.1节中的以下文字“如基于Transformer模型的异常分析方法通过自注意力机制来有效捕捉时间序列中长距离的时序依赖关系，基于图神经网络的异常分析方法通过建模数据点之间的关系来有效地捕捉不同变量维度数据间的空间结构信息”，2.3节的以下文字“图神经网络（Graph Neural Network, GNN）是一类专门用于处理图结构数据的深度学习模型，广泛应用于社交网络分析、推荐系统、生物信息学以及时间序列分析等领域。与传统神经网络不同，GNN能够直接处理图结构中节点之间复杂的连接关系，并通过端到端的学习方式自动提取图中隐含的结构性模式”等。
- 3.本文所有插图均已改为手动重新绘制，因此无引用的图片。
- 4.论文原先的标题为“基于多维时间序列的港口设备异常检测系统”，后考虑到体现文章研究内容和应用场景，将标题改为“面向港口设备的多维时间序列异常检测及异常预测技术研究”。

(2) 虽然增加了新的对比方法，但是建议在相关工作方面，尤其是针对港口设备这个场景下，现有工作与本文目标的差异，以及挑战是什么，然后给出解决方案。

修改说明：

在1.2节中介绍国内外研究现状时，增加了对目前相关研究在港口设备场景下的局限性分析，如增加了“但是卷积神经网络因为其卷积操作具有固定的感受野而难以有效建模时间序列的长时间依赖关系，而通过叠加大量卷积层或使用膨胀卷积来扩大卷积感受野的方法会增加模型复杂度和训练难度”、“生成式对抗网络难以建模时间序列的时序依赖关系，同时需要大量数据来学习真实分布，难以有效分析样本稀缺场景下的时间序列”、“基于Transformer模型的异常检测方法主要针对时间序列的时间维度进行建模分析，忽视了多维时间序列中不同变量维度之间的空间相关性对异常检测的重要性，并且Transformer模型将单个数据点作为token进行输入训练的方法无法有效捕捉时间序列的局部特征，其内部的全局注意力机制在处理多维时间序列时会对所有变量维度统一进行混合模式的学习，无法准确学习到各个变量内部的异质性特征”等内容。

同时在1.3节介绍本文研究挑战时，具体分析了港口设备时序数据的特点、现有方法在港口设备场景下的挑战，并在1.4节介绍本文研究内容时针对现有方法的挑战给出了对应的解决方案，同时对本文摘要做出了修改，重点突出相关研究挑战和本文解决方案。

专家2初审意见修改说明：

（1）引言综述选题意义部分需要对于港口设备的具体类型、关键运行参数以及异常情况对港口运营的具体影响等关键之处深入分析。

修改说明：

在1.1节介绍本文研究背景和意义时，以港口设备岸桥为例，具体分析了其关键运行参数及异常情况对港口运营的具体影响，相关内容如下“在众多港口设备中，岸桥作为负责船岸之间集装箱装卸作业的核心装备，其运行状态对整个港口作业流程具有重要影响。岸桥往往配备了大量传感器，可实时采集包括加速度、电机电流、钢丝绳张力、液压压力与振动信号等多种类型的运行参数，这些运行参数不仅反映了岸桥当前的工作状态，还蕴含着潜在的异常前兆信号。例如加速度用于监控桥架运行过程中的加速度变化，异常的加速度变化可能表示岸桥在启动或制动过程中出现异常，如驱动系统响应不稳定或控制系统失调；电流反映电机工作负载情况，持续偏高的电流可能表示电机过载、机构卡滞或阻力异常，是电气系统故障的重要指标；钢丝绳张力主要监控吊具系统的受力状态，张力突变可能代表起升过程中的冲击载荷或制动失效；液压压力用于监控夹具控制的状态，液压系统泄漏或压力异常会直接导致抓取失败或操作失控；振动信号用于监测齿轮箱的运行状态，异常振动信号常与轴承磨损或松动等机械故障有关。岸桥设备一旦发生故障，其影响往往是连锁且严重的，轻则造成单个泊位作业延误，重则引发港区拥堵、调度失衡，甚至造成船舶滞港，增加滞期费与索赔风险，对港口运营效率与经济效益造成严重影响”。

（2）在异常检测模型MTAD-TSD中，对于时间维度和空间维度特征融合的方式相对较为简单，将时间特征和空间特征进行拼接后输入到异常检测模块，需要深入挖掘两者之间潜在的复杂交互关系。

修改说明：

在3.4.4节中，增加对MTAD-TSD的时空特征融合策略的详细描述，并在3.5.3节消融实验中对不同的时空特征融合策略进行消融实验分析，如“消融时空特征融合模块后，MTAD-TSD的异常检测性能也有小幅的下降，因为时空特征融合模块基于双向交叉注意力机制进行时间和空间维度的特征融合，相比于通过简单

的特征拼接操作进行特征融合，能更好地建模时空特征之间的深层依赖关系，增强模型的特征表达能力”等内容。

(3) 在特征学习过程中，对于不同尺度特征之间的权重分配和融合策略缺乏详细的阐述，需要充分考虑不同尺度特征在异常预测中的相对重要性。

修改说明：

在 4.4.3 节描述多尺度特征学习模块时，增加对多尺度特征融合策略的描述,内容如下：“最终经过多轮的迭代与分段拼接操作，MTAP-DM 构建了一组具有不同时间尺度的分段序列集合 $X_m = \{x_1, x_2, \dots, x_a\}$ ，这些分段序列对应着时间序列在不同尺度下的行为模式。随后分段序列集合 X_m 会被输入到多尺度编码器中进行多尺度特征提取，多尺度编码器由 a 个并行子编码器组成，每个子编码器专门负责处理对应尺度下的分段序列 x_i ，以保证在不同时间尺度下的异常前兆数据特征均能被有效捕捉。每个子编码器基于 Transformer 结构实现，首先通过嵌入层将每个分段序列 x_i 映射为对应的嵌入表示 $x_{i,e}$ ，将输入数据从原始空间投射到高维特征空间，随后嵌入后的序列 $x_{i,e}$ 会被输入到多头自注意力层中，通过并行注意力捕捉序列中不同时间步之间的长期依赖关系与跨时间尺度的动态特征，从而实现对时间特征的深层次建模，如公式（4.12）和公式（4.13）所示， Z 是通过尺度编码器学习到的多尺度特征集合。

$$z_p = \text{Transformer}(x_{p,e}) \quad (4.12)$$

$$Z = \{z_1, z_2, \dots, z_a\} \quad (4.13)$$

多尺度特征集合 Z 表征了输入时间序列在不同尺度下的时序特征，为了实现对原始时间序列的准确重构，需将这些分布在不同时间尺度上的局部特征融合为一致的全局特征表示。MTAP-DM 通过解码器进行多尺度特征融合，解码器由多层感知机构成。具体而言，首先将所有尺度的编码特征 z_i 进行拼接后输入到 MLP 解码器中，通过一系列线性变换与非线性激活操作对多尺度特征进行非线性融合与转换，最终生成表示原始时间序列整体特征模式的输出特征向量 R ，如公式（4.14）所示。

$$R = \text{Decoder}(Z) \quad (4.14)$$

”。

(4) 在对比实验中，比较的算法有待商榷，且对于这些对比方法的参数设置和优化细节分析不足。

修改说明：

在3.5.1.4节和4.5.1.4节描述对比算法时，增加相关对比算法的参数和优化细

节分析，如“由于目前多维时间序列异常预测研究较为缺乏，专门用于多维时间序列异常预测的模型或者算法较少，因此本章选取了一种专门用于多维时间序列异常预测任务的模型PAD和另外七种基于序列重构的多维时间序列异常检测模型进行对比实验，用于评估MTAP-DM在多维时间序列异常预测任务中的性能。为了使这七种异常检测模型能够适用于异常预测任务，本实验的处理方式是

将这些异常检测模型的重构序列输入到输出层，同时在这个输出层中拟合一个从当前窗口的重构序列到下一时间窗口异常标签的映射函数”等内容。

（5）当移除空间维度特征学习模块时，需要详细分析哪些具体的空间特征对异常检测最为关键以及原因。

修改说明：

在3.5.3节消融实验中，具体分析了哪些空间特征对异常检测最为关键，相关内容如下“消融空间维度特征学习模块也会大幅降低MTAD-TSD的异常检测性能，因为空间维度特征学习模块能够有效构建时间序列各个变量间的局部动态图结构和全局静态图结构，局部动态图结构使得模型能够充分学习时序变量间的局部动态相关性，有效捕捉了时序数据中复杂的短时变化模式，同时全局静态图结构使得模型能够全面刻画时序变量间的全局静态相关性，保持对数据全局变化趋势的建模能力，使得模型学习到的空间维度特征更为准确、充分”。

（6）论文的语言需要仔细梳理。

修改说明：

仔细校对文章内容，删除一些不必要的词语和内容，如多余的“本文”、“本章”等；调整文章段落结构，使文章内容更具有逻辑性；优化部分口语化描述，使文章内容更符合学术规范性。